Proyecto final Python para Ciencia de Datos

Franco Purtscher 5634307-8

Introducción:

En este trabajo se utilizará una base de datos sintética extraída de Kaggle, que contiene información sobre intentos de ciberataques. Con ella intentaremos conocer y analizar estos ataques, por ejemplo, como y donde se llevan a cabo, que particularidades tienen, que patrones existen, entre otras cosas. Y también observarlo desde al lugar de la víctima, sobre como reacciona o como le afecta. Para ello, se aplicarán medidas de resumen, tablas, gráficos, y entrenaremos algunos modelos de machine learning para predecir diferentes aspectos de estos ataques.

La ciberseguridad es un tema muy importante, delicado, el cual se debe conocer y enfatizar para evitar inconvenientes que pueden ser graves, y por ello es un tema intereseante de investigar. Aunque siempre teniendo claro que el objetivo principal es explorar, analizar datos, aplicar técnicas estadísticas.

Datos:

Como se mencionó en la introducción, el dataset fue creado artificialmente de manera realista, sin ningún tipo de información personal.

Contiene toda la información de cada ataque, desde el primer momento en que se intenta hasta las consecuencias finales en la víctima.

Principal información del dataframe:

```
Filas: 100000
Columnas: 50
Tipos de columnas:
int64      25
str        14
float64    11
Cantidad de ataques ('Incident_ID'): 100000
```

Eliminanos las filas duplicadas:

```
Columnas: 100000
Cantidad de ataques ('Incident_ID'): 100000
```

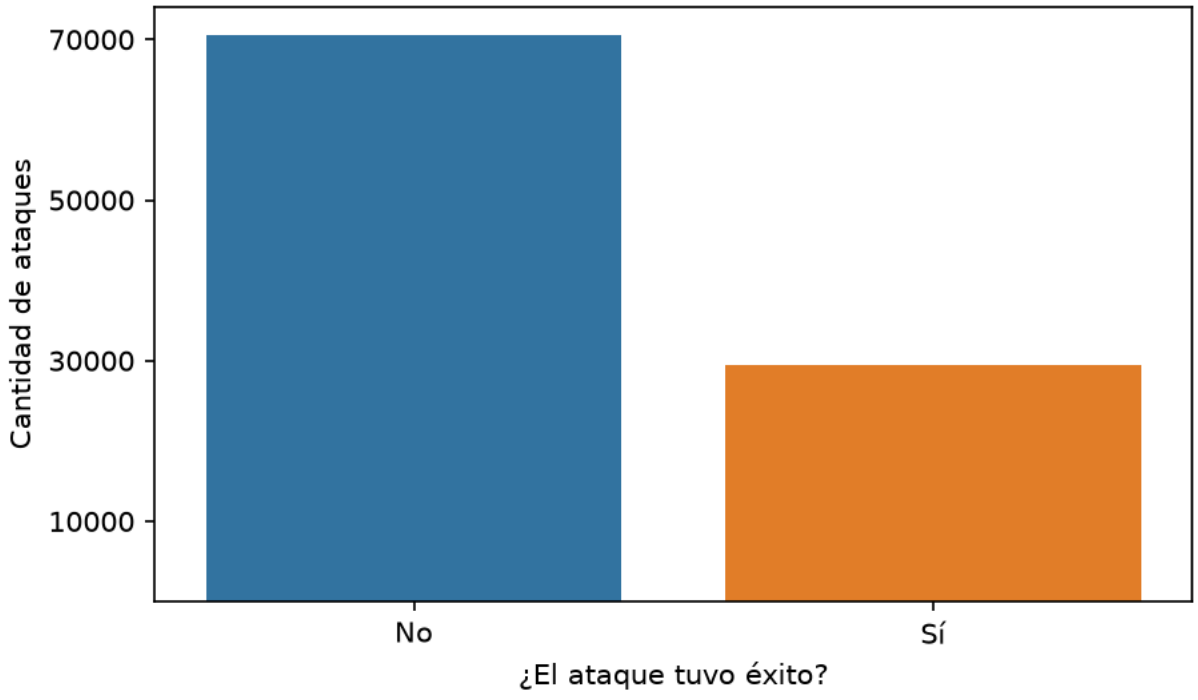
```
Cantidad de datos faltantes por columna:
Recovery_Cost_USD     70594
Compliance            42772
Financial_Loss_USD     5006
Detection_Time_Min     3147
Company_Size              0
Employee_Count            0
...                       0
```

Entonces tenemos una base de datos con 100000 ataques diferentes y 50 variables que caracterizan cada uno de ellos. De estas 50, tenemos 25 númericas discretas, 11 continuas y 14 cualitativas. Debemos tener en cuenta que algunas de las 25 discretas, son binarias, que valen 1 si la observación cumple con esa variable, y 0 en caso contrario.

Las variables de respuesta o interés de este analisis son: `Attack_Success` que indica si el ataque tuvo éxito o no, y `Cyber_Risk_Score` que numera del 1 al 100 cada ataque según su nivel de riesgo.

Distribución de variables de interés

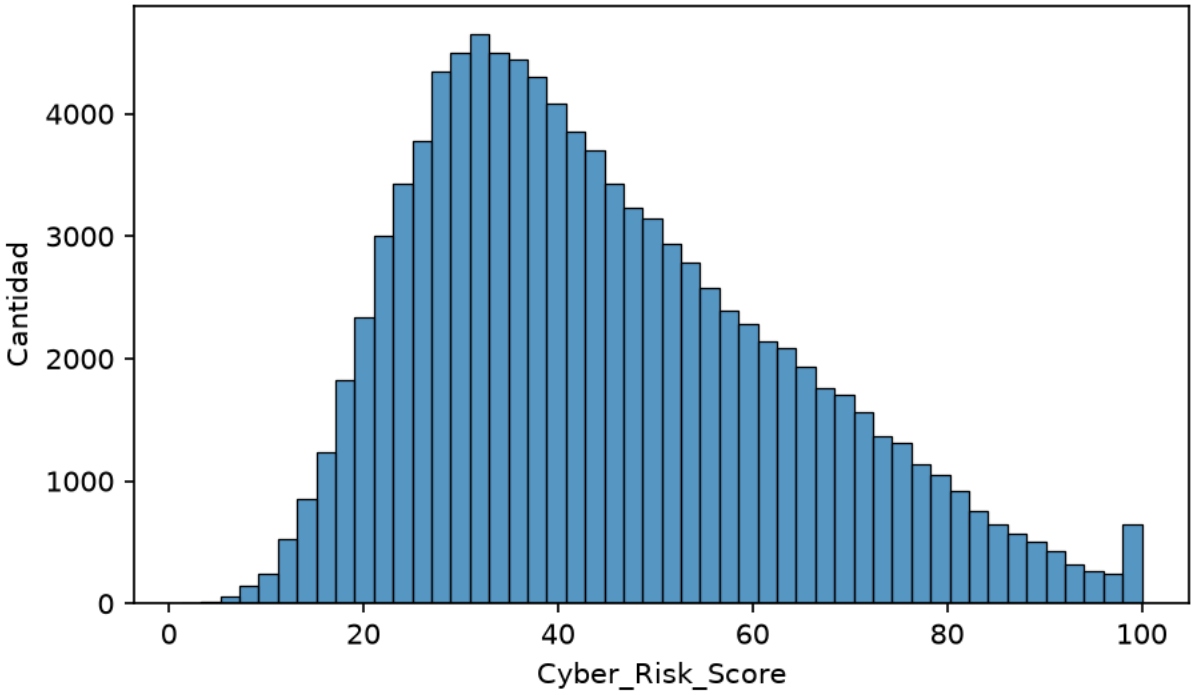
Frecuencia de `Attack_Succes`:

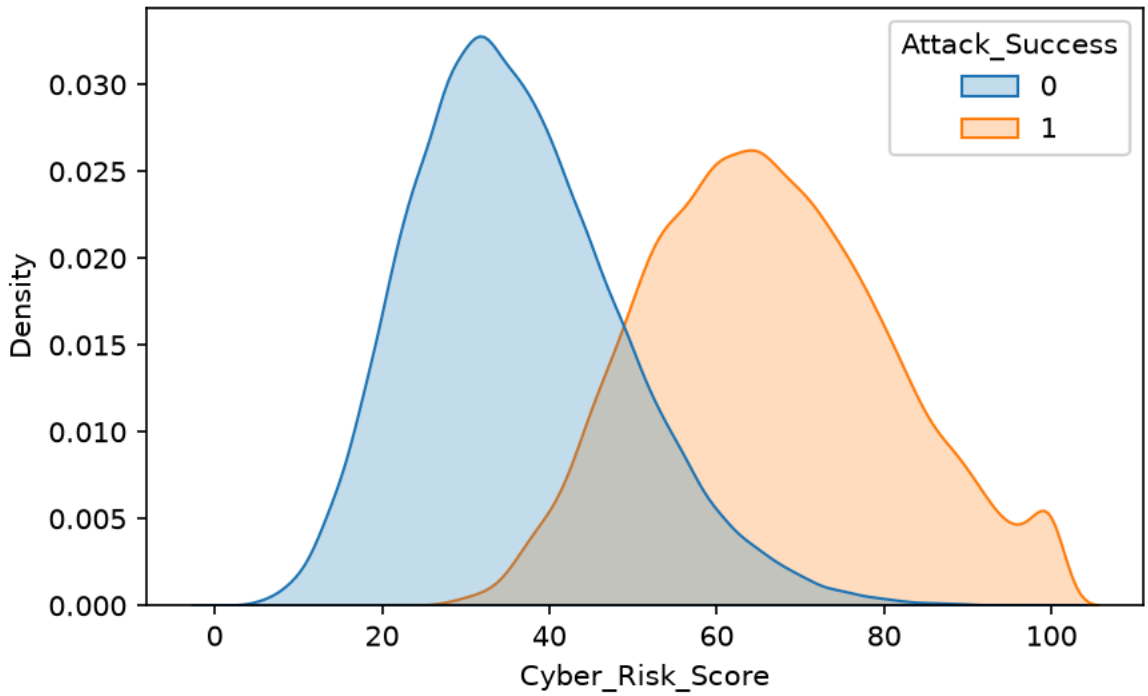


Vemos que de todos los ataques, 70000, que equivale al 70%, fracasó y 30% restante efectivamente tuvo éxito. Estas cantidad exactas están claramente asociadas a la sinteticidad de los datos. En datos reales, es muy poco probable que existan estos porcentajes enteros.

Distribución `Cyber_Risk_Score`:

```
count    100000.000000
mean         45.005120
std          19.047731
min           1.337935
25%          30.387444
50%          41.635008
75%          57.437351
max         100.000000
Name: Cyber_Risk_Score, dtype: float64
```

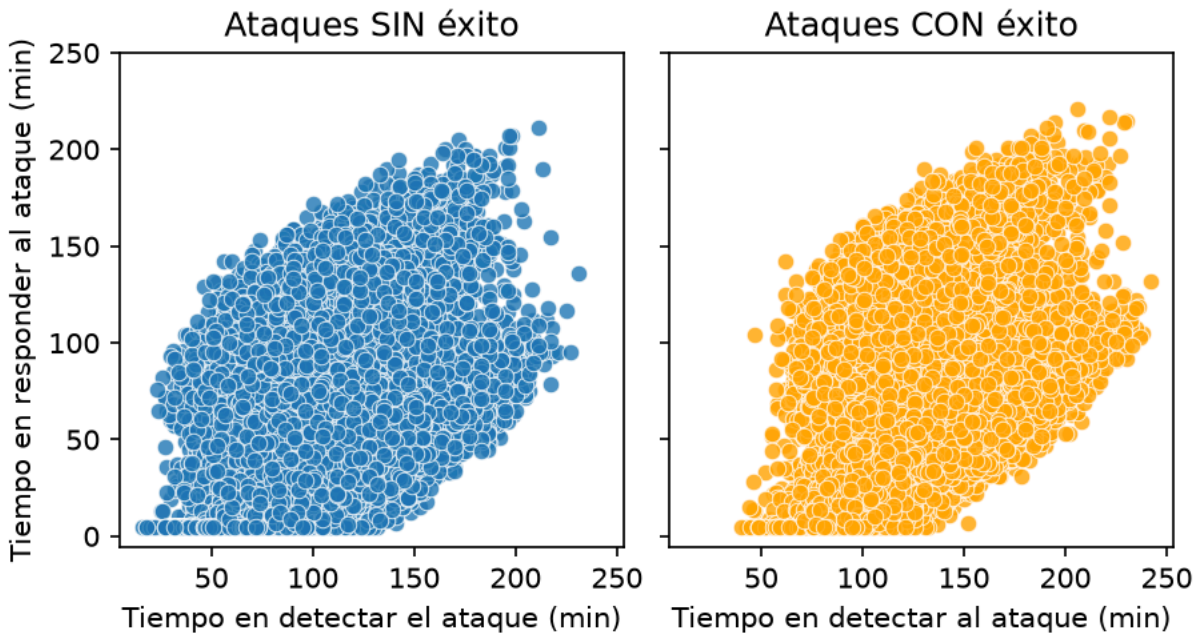




EL nivel de riesgo del ataque observamos que tiene una distribución, con media 45 y asimetría a la derecha, donde el tercer percentil es 57.4 y el máximo 100. Destacando el último intevalo que rompe con el patrón, y tiene bastante observaciones relativamente.

Análisis exploratorio

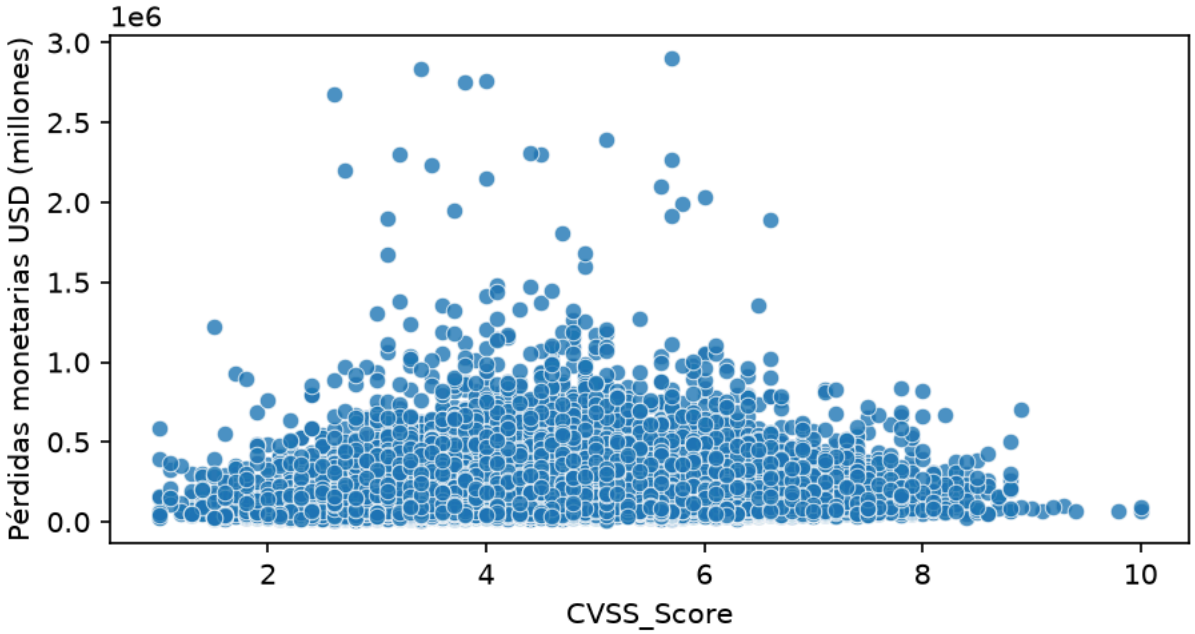
¿Un ataque que tuvo éxito fue más díficil de detectar?



¿El desarrollo en seguridad de la empresa evita ataques?

Security_Maturity	Total_de_ataques	Cantidad_de_exitos	Proporcion_de_exitos
0	49	17	0.346939
20	805	350	0.434783
40	6340	2551	0.402366
60	23522	8002	0.340192
80	41379	12010	0.290244
100	27905	6476	0.232073

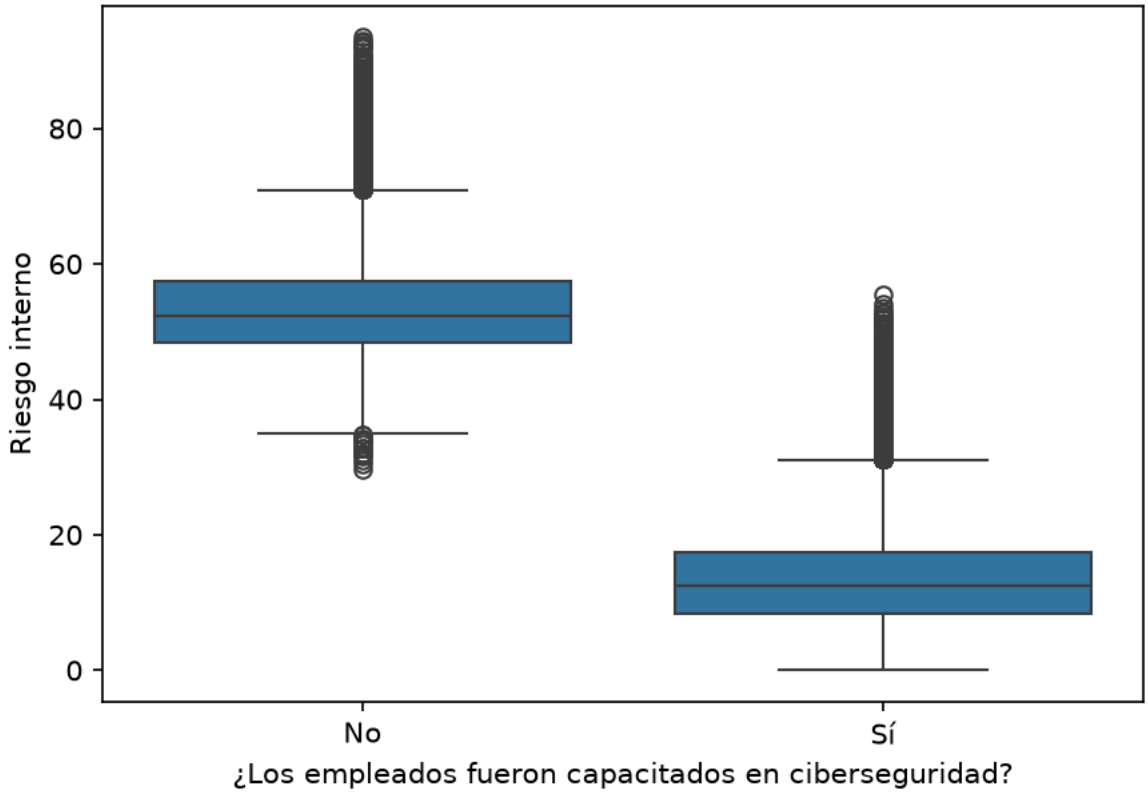
¿



CVSS_Score es la puntuación media del Sistema Común de Puntuación de Vulnerabilidades. Se filtró `Financial_Loss_USD` menores a tres millones para que la escala y el gráfico sea más legible.

¿Capacitar a los empleados disminuye el riesgo?

```
[Text(0.5, 0, '¿Los empleados fueron capacitados en ciberseguridad?'),
 Text(0, 0.5, 'Riesgo interno')]
```



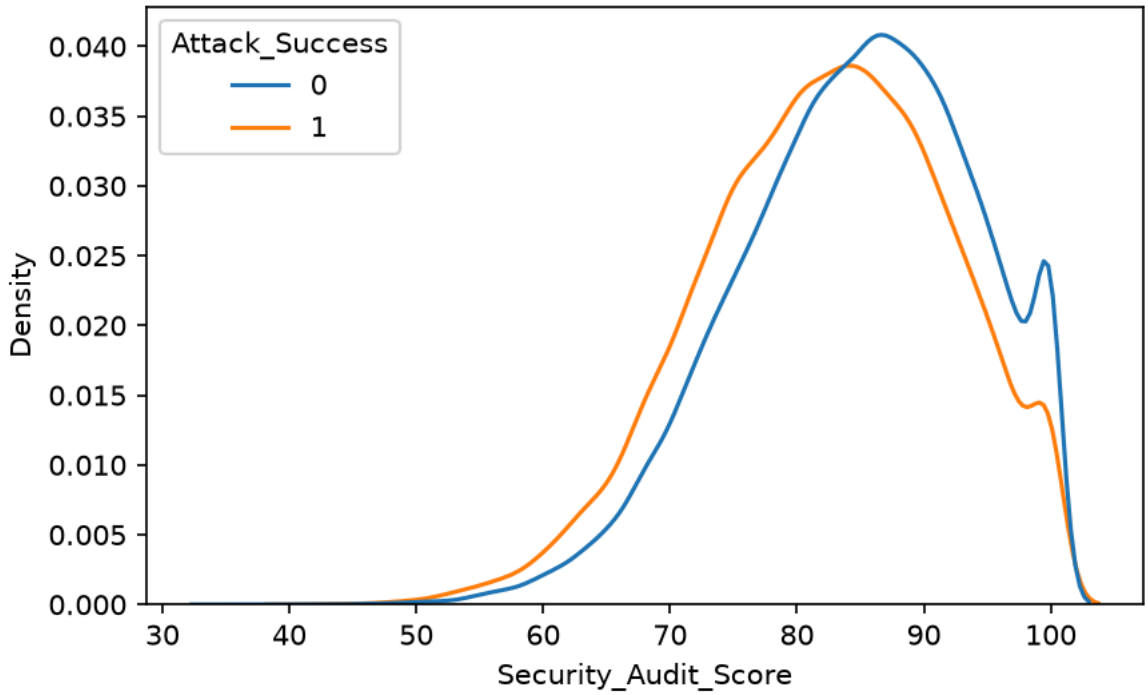
La variable `Insider_Risk` mide entre 0 y 100 el riesgo de ataques por causas internas(empleados descuidados o malintencionados)

¿El tamaño del equipo de SOC influye en posibles ataques?

cat_SOC	Total_de_casos	Cantidad_de_exitos	Proporcion_de_exitos
Bajo	25036	7395	0.295375
Medio	25046	7334	0.292821
Alto	24943	7394	0.296436
Muy Alto	24975	7283	0.291612

`Attack_Success` y la proporción de empleados en el equipo de SOC son independientes

¿Quienes tienen mayor puntuación en la auditoria de ciberseguridad reciben menos ataques?



`Security_Audit_Score` es la puntuación de la empresa en auditoría de ciberseguridad.

MODELOS DE PREDICCIÓN

DOS MODELOS:

1- Clasificación: Predecir si el ataque tuvo éxito `Attack_Success`

2- Regresión: Predecir el nivel de riesgo del ataque `Cyber_Risk_Score`

Árbol de decisión

Para clasificar la variable `Attack_Success` realizaremos un árbol de decisión.

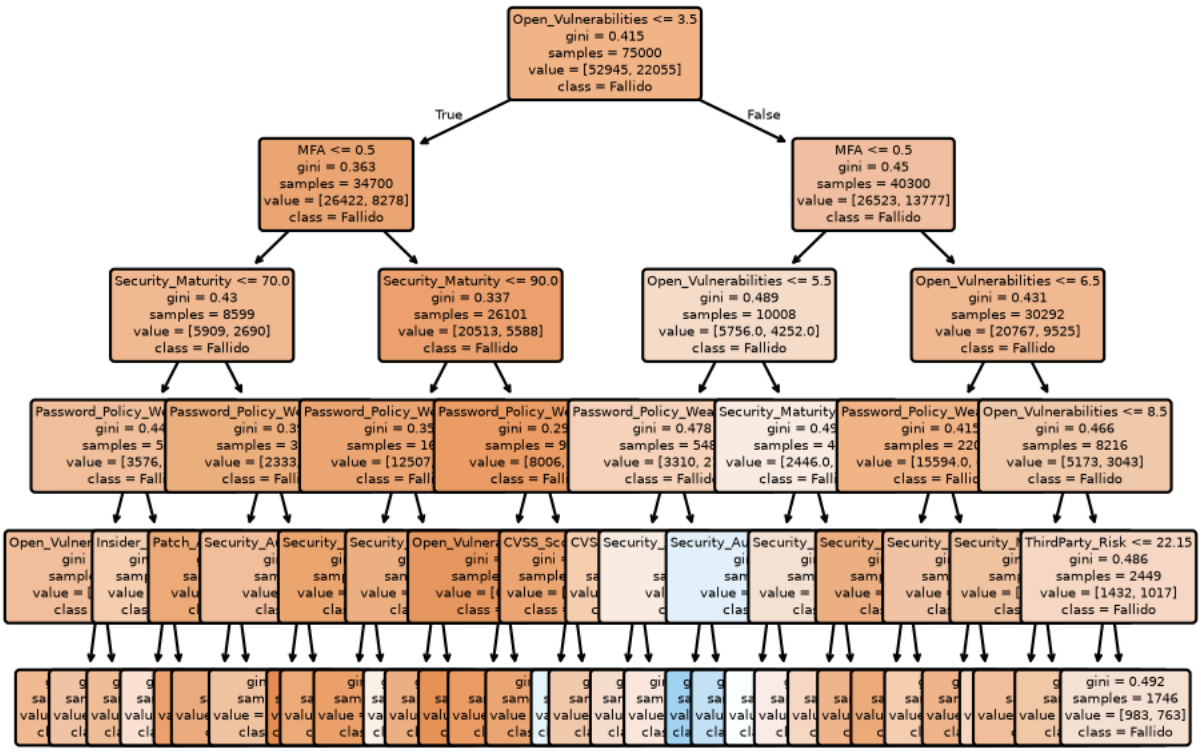
De las 50 variables, muchas caracterizan las consecuencias del ataque o como fue el ataque en sí. Por ende, si nuestro modelo quiere predecir si un ataque tuvo éxito o no, podríamos usar este tipo de variable, pero lo interesante sería intentar predecir, si un ataque va a tener éxito o no, analizando las caracteristicas de la empresa, antes de que un ataque suceda. Es decir, si queremos saber si un ataque tuvo éxito, y miramos la variable que mide la pérdidas económicas por el ataque, está claro que si el valor es alto, el ataque sucedió. Entonces las variables que vamos a usar, son aquellas que caracterizan a la empresa, en aspectos generales y en tanto a la defensa ante ataques. Asumimos que el ataque 'va a suceder' pero no sabemos como, y queremos predecir que tan factible es que suceda.

Parámetros utilizados en el árbol:

```
{'ccp_alpha': 0.0,
 'class_weight': None,
 'criterion': 'gini',
 'max_depth': 5,
 'max_features': None,
 'max_leaf_nodes': None,
 'min_impurity_decrease': 0.0,
 'min_samples_leaf': 1,
 'min_samples_split': 2,
 'min_weight_fraction_leaf': 0.0,
 'monotonic_cst': None,
 'random_state': 123,
 'splitter': 'best'}
```

El único parámetro que se varió fue 'max_depth', la cantidad máxima de nodos del árbol, con un valor pequeño, para poder visualizar gráficamente las decisiones que toma el árbol.

Gráfico del árbol de decisión:



Matriz de confusión del árbol sobre los datos de test:

```
array([[17477,   172],
       [ 7189,   162]])
```

Las filas indican los valores reales y las columnas las predicciones. El valor en la posición (0,0) representa la cantidad de observaciones donde el valor real era 0 (no éxito) y se predijo 0.

Métricas de evaluación:

```
              precision    recall  f1-score   support

           0       0.71      0.99      0.83     17649
           1       0.49      0.02      0.04      7351

    accuracy                           0.71     25000
   macro avg       0.60      0.51      0.43     25000
weighted avg       0.64      0.71      0.60     25000
```

Bosque aleatorio de regresión

Para predecir la variable `Cyber_Risk_Score` realizamos un random forest, que al ser una variable continua, se le denomina de regresión.

En la misma línea que el árbol, para predecir el nivel de riesgo de un ataque, mediante un random forest, no utilizaremos todas las variables. Primero definamos a que se refiere la variable con nivel de riesgo. Lo vamos a definir como que tan probable es que

Elección de hiperparámetros a través de validación cruzada:

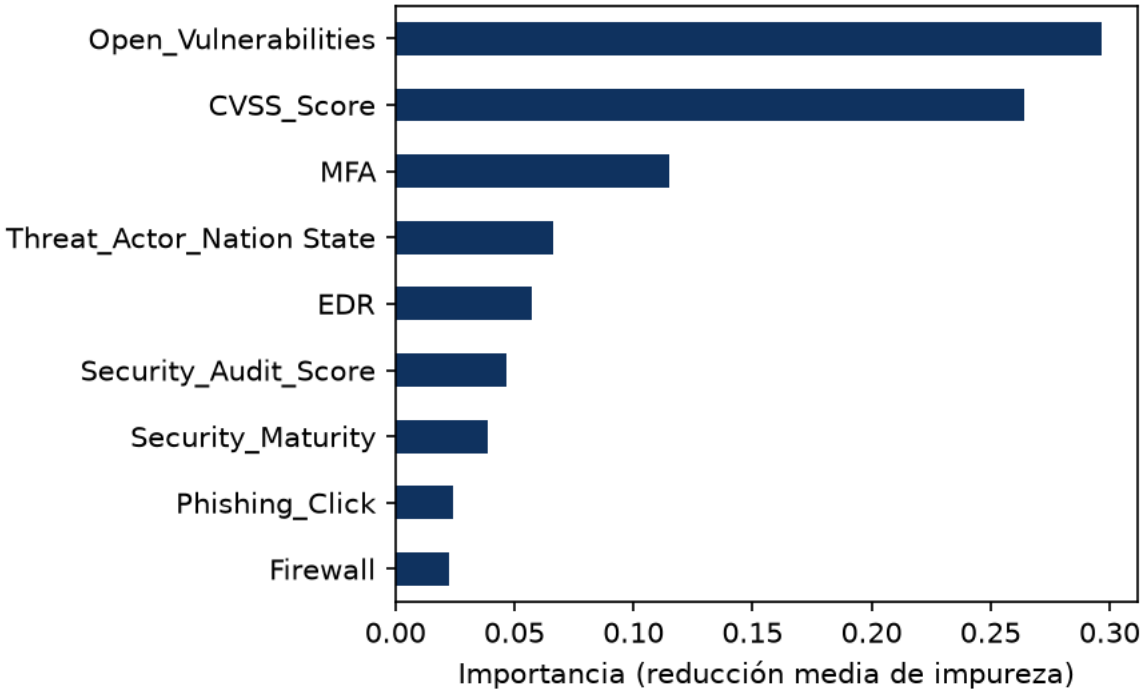
Se simularon las siguientes combinaciones, con un CV = 4: “max_depth”: [5, 10, None] - “max_features”: [0.2, 0.5, 1.0]

```
({'max_depth': 10, 'max_features': 0.5}, np.float64(0.546))
```

Métricas de evaluación:

```
MAE     10.69
RMSE    12.70
R2       0.55
dtype: float64
```

Importancia de las variables para predecir:



Referencias:

Link del dataset: Cyber Attack Detection and risk prediction dataset